



数字媒体技术基础

Meng Yang

www.smartllv.com

SUN YAT-SEN University



**机器智能与先进计算教
育部重点实验室**



**智能视觉语言
学习研究组**

4 媒体信息表示基础



Course Outline

- 4. 3变换空间表示方法 8
 - 4. 3. 1 主成分分析 8
 - 4. 3. 2 频域分析 8
 - 4. 3. 3 卷积分析 8
- 4. 3 统计信息表示方法 8
 - 4. 3. 1 统计直方图模型 8
 - 4. 3. 2 词袋模型 8
 - 4. 3. 3 Skip-gram 模型 8

4. 3变换空间表示方法

变换空间表示方法

❑ 概述

- 新表示 = 函数(原始表示)

❑ 主成分分析

❑ 频域分析




❑ 卷积分析

主成分分析



PCA基础

你的数据是多少维的？



□ 常见的数据特点

- 数据各维度之间不是互相独立的
 - ❖ 数据的内在维度 (intrinsic dimensionality) 通常远低于其表面维度
 - ❖ 因此，需要降低数据维度 (dimensionality reduction)
 - ❖ PCA在降维方法中（可能）是最常用的一种



这是谁？

$$96 \times 108 = 10368?$$

主成分分析

□ Starting point: 零阶表示

- ✓ Zero-dimensional representation
- ✓ 不允许使用任何维度，如何最佳表示 \mathbf{x} ?
- ✓ 寻找某个固定(constant)的 \mathbf{m} ，使得

$$J_1(\mathbf{m}) = \min_{\mathbf{m}} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2$$

- ✓ 最优解：(证明?)

$$\mathbf{m}^* = \operatorname{argmin}_{\mathbf{m}} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{m}\|^2 = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$



主成分分析

□ 一维表示：数据维度间的线性关系

- ✓ 如同前面的例子
 - 数据是 d 维
 - 但是内在维度可能是 m 维的, $m < d$ 或者 $m \ll d$
 - PCA用线性关系来降低维度
- ✓ $\mathbf{x} \in \mathbb{R}^d$: 原来的高维数据 (随机变量)
 - 训练样本: $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ✓ 假设 $m = 1$, 用原数据的单个线性组合来表示
 - $y_i = \mathbf{w}^T \mathbf{x}_i + b$
 - y_1, y_2, \dots, y_n — 新的数据/特征(features)
 - 如何寻找最佳的 \mathbf{w} ? 如何找到最佳的 b ?

主成分分析

❑ Idea: 选择什么方向? 为什么?



✓ 什么方向**最优**?

主成分分析

□ 形式化formalization: 最大化方差

✓ 方差是衡量新特征包含信息多少的度量

- 有时也称为能量energy

✓ 优化目标函数 $J_2(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \|\mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}})\|^2$

✓ 发现问题了吗?

- $J_2(\mathbf{w})$ 可以是无穷大或者无穷小!
- 最常用的解决办法: 加上限制条件 $\|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w} = 1$

$$\operatorname{argmax}_{\mathbf{w}} \frac{1}{n} \sum_{i=1}^n \|(\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}\|^2$$

$$\text{s. t.} \quad \mathbf{w}^T \mathbf{w} = 1$$

- s.t. —subject to, 表示约束条件constraint(s)

主成分分析

□ 简化simplification 变换transformation

$$\begin{aligned}\|(\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}\|^2 &= ((\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w})^T ((\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}) \\ &= \mathbf{w}^T (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}\end{aligned}$$

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n \|(\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w}\|^2 &= \mathbf{w}^T \sum_{i=1}^n \frac{1}{n} (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \mathbf{w} \\ &= \mathbf{w}^T \text{Cov}(\mathbf{x}) \mathbf{w}\end{aligned}$$

主成分分析


□ 优化optimization

- ✓ 拉格朗日乘子法 Lagrange multipliers
 - 将有约束的优化问题转化为无约束的优化问题
- ✓ Lagrangian 拉格朗日函数
$$f(\mathbf{w}, \lambda) = \mathbf{w}^T \text{Cov}(\mathbf{x}) \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{w} - 1)$$
- ✓ λ : 拉格朗日乘子 Lagrange multiplier
- ✓ 最优的必要条件: $\frac{\partial f}{\partial \mathbf{w}} = \mathbf{0}, \quad \frac{\partial f}{\partial \lambda} = 0$
- ✓ $\frac{\partial f}{\partial \mathbf{w}} = 2\text{Cov}(\mathbf{x})\mathbf{w} - 2\lambda\mathbf{w} = \mathbf{0}$
 - 我们这里的前提条件是什么?
 - 应该想到用哪一个公式?
- ✓ $\text{Cov}(\mathbf{x})\mathbf{w} = \lambda\mathbf{w}, \quad \mathbf{w}^T \mathbf{w} = 1!$

主成分分析

□ 选哪个特征向量？

- ✓ $J_2(\mathbf{w}) = \mathbf{w}^T \text{Cov}(\mathbf{x}) \mathbf{w} = ?$
- ✓ $\text{Cov}(\mathbf{x})$ 是半正定的（如何证明？）
- ✓ 选取 λ_1 （即最大特征值）对应的特征向量 ξ_1 为 \mathbf{w}_1
 - 为什么？约束条件满足了吗？
- ✓ 怎样用 \mathbf{w}_1 来近似 \mathbf{x} ？
 - 投影！
 - $\mathbf{x} \approx \bar{\mathbf{x}} + (\mathbf{w}_1^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_1$
 - 所以， $y_i = \mathbf{w}_1^T (\mathbf{x} - \bar{\mathbf{x}})$
 - 那么， $b = ?$



主成分分析

□ J_1 和 J_2 的等价关系

✓ 若干向量

- \mathbf{x}_i : 降维之前的向量
- $\mathbf{w}_1^T(\mathbf{x}_i - \bar{\mathbf{x}})\mathbf{w}_1 = y_i\mathbf{w}_1$: 降维之后的向量
- $\hat{\mathbf{x}}$: 在原空间中重建的向量
- 目前的重建关系: $\hat{\mathbf{x}}_i \approx \bar{\mathbf{x}} + y_i\mathbf{w}_1$

✓ J_1 的目的是使得 $\hat{\mathbf{x}}_i$ 和 \mathbf{x}_i 尽可能相差小($\bar{\mathbf{x}}$ 固定为均值)

- $J_1(\mathbf{w}, \mathbf{a}) = \sum_{i=1}^n \frac{1}{n} \|\mathbf{x}_i - (\bar{\mathbf{x}} + a_i\mathbf{w})\|^2$
- \mathbf{w} : 投影方向, a_i : 投影系数

✓ 最小化 J_1 得到的 a_i 和 \mathbf{w} 与 J_2 得到的结果完全一致!

- 试着去证明!

主成分分析

□ 如果需要更多投影方向？

✓ What if we need $\mathbf{w}_2, \mathbf{w}_3, \dots$

- 新的投影方向需要继续保持“能量”
- 但是需要限制
- $\mathbf{w}_2 \perp \mathbf{w}_1, \mathbf{w}_3 \perp \mathbf{w}_2, \mathbf{w}_3 \perp \mathbf{w}_1, \dots$

✓ 在上述限制条件下

- $\mathbf{w}_2 = \boldsymbol{\xi}_2, \mathbf{w}_3 = \boldsymbol{\xi}_3, \dots$
- 重建系数: $\mathbf{w}_j^T (\mathbf{x} - \bar{\mathbf{x}})$

✓ 总之，

$$\mathbf{x} \approx \bar{\mathbf{x}} + (\mathbf{w}_1^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_1 + (\mathbf{w}_2^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_2 + \dots$$

主成分分析

重建和原数据的关系

- ✓ 假设 $n > d$ ，即数据比维数多
 - 进一步假设 $\text{Cov}(\mathbf{x})$ 可逆
 - 如果 $n < d$ ，那么情况如何、还能做PCA变换吗？
- ✓ $\text{Cov}(\mathbf{x})$ 是 $d \times d$ 矩阵，有 d 个互相垂直的特征向量 ξ_i
 - 重建会有 d 个互相垂直的投影方向 \mathbf{w}_i

$$\forall \mathbf{x}, \quad \mathbf{x} = \bar{\mathbf{x}} + \sum_{i=1}^d (\mathbf{w}_i^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_i$$

- 将 \mathbf{w}_i 拼成矩阵形式 $W = [\mathbf{w}_1 \ \mathbf{w}_2 \ \cdots \ \mathbf{w}_d]$ ($d \times d$)
- 投影系数是 $W^T(\mathbf{x} - \bar{\mathbf{x}})$ ，投影方向是 W
- $\mathbf{x} = \bar{\mathbf{x}} + WW^T(\mathbf{x} - \bar{\mathbf{x}})$ (为什么?)
- 重建是完全精确的 (没有误差)，为什么？

主成分分析

降维

✓ 很多时候，有些投影方向是噪声

- 需要扔掉一些方向
- 扔掉哪些？扔掉多少？

✓ 去掉特征值最小的那些

✓ 通常保持90%的能量

$$\frac{\lambda_1 + \lambda_2 + \dots + \lambda_T}{\lambda_1 + \lambda_2 + \dots + \lambda_d} > 0.9$$

- 寻找第一个 T ，使得上面的不等式成立

主成分分析

降维的损失

- ✓ 现在 $\hat{W} = [\mathbf{w}_1 \ \mathbf{w}_2 \ \cdots \ \mathbf{w}_T] \ (d \times T)$
- ✓ $\mathbf{x} - \hat{\mathbf{x}} = \sum_{j=T+1}^d (\mathbf{w}_j^T (\mathbf{x} - \bar{\mathbf{x}})) \mathbf{w}_j = \sum_{j=T+1}^d \mathbf{e}_j$
 - 这个误差多大?
 - $\mathbf{e}_j^T \mathbf{e}_k = 0$ 如果 $j \neq k$ (为什么?)
 - $E(\|\mathbf{x} - \hat{\mathbf{x}}\|^2) = \sum_{j=T+1}^d E(\|\mathbf{e}_j\|^2)$ (为什么?)
 - $E(\|\mathbf{e}_j\|^2) = \lambda_j$ (为什么?)
- ✓ 这样降维保证平均 (期望) 重建误差最小
 - 直接优化重建误差 J_1 得到同样的结果

主成分分析

□ 小结：PCA变换的步骤

- ✓ 训练样本： $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$
- ✓ 计算得到 $\bar{\mathbf{x}}$ 和 $\text{Cov}(\mathbf{x})$
- ✓ 求得 $\text{Cov}(\mathbf{x})$ 的特征值和特征向量
 - Matlab, R, octave, ...
- ✓ 根据特征值选定 T
- ✓ 根据 T 的值确定矩阵 \hat{W}

- ✓ 对任何数据 \mathbf{x} ，其新的经过PCA变换得到的特征是
$$\mathbf{y} = \hat{W}^T (\mathbf{x} - \bar{\mathbf{x}})$$
重建则为 $\mathbf{x} \approx \hat{\mathbf{x}} = \bar{\mathbf{x}} + \hat{W} \mathbf{y}$

频域分析

- 对于二维信号，其频谱的表示如下，其中
 - 高频部分代表细节、边缘和噪声
 - 低频占据绝大多少能量，其中直流分量（零频）能量占比最大。
 - 频率分布具有中心对称性
- 傅里叶变换公式

Fourier transform (FT) (Fourier integral)

$$X(j\omega) = \int_{-\infty}^{\infty} x(t)e^{-j\omega t} dt$$

Analysis equation

To obtain the spectrum


Inverse Fourier transform

$$x(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} X(j\omega)e^{j\omega t} d\omega$$

Synthesis equation

A linear combination of $e^{j\omega t}$


频域分析




频域分析



Spatial domain visualization



Frequency domain visualization



❑ 卷积的定义：


- 卷积是两个变量在某范围内相乘后求和的结果。如果卷积的变量是序列 $x(n)$ 和 $h(n)$ ，则卷积的结果：

$$y(n) = \sum_{i=-\infty}^{\infty} x(i)h(n-i) = x(n) * h(n)$$

<http://blog.csdn.net/chaipp0607>

<https://blog.csdn.net/chaipp0607/article/details/72236892>

卷积分析



<http://blog.csdn.net/chaipp0607>




卷积分析



| | | |
|----|----|----|
| -1 | -1 | -1 |
| -1 | 9 | -1 |
| -1 | -1 | -1 |

| | | |
|------|------|------|
| 1/16 | 2/16 | 1/16 |
| 2/16 | 4/16 | 2/16 |
| 1/16 | 2/16 | 1/16 |

<https://blog.csdn.net/chaipp0607>



4.4 统计信息表示方法



统计信息表示方法

- ❑ 统计直方图模型
- ❑ 词袋模型
- ❑ Skip-gram 模型



直方图表示

■ 概述

- 直方图(Histogram)，又称质量分布图，是一种统计报告图，由一系列高度不等的纵向条纹或线段表示数据分布的情况。一般用横轴表示数据类型，纵轴表示分布情况。

直方图表示


□ 图像直方图

- 假设有一个矩阵包含一张图像的信息（灰度值 0 - 255），既然已知数字的范围包含 256 个值，于是可以按一定规律将这个范围分割成子区域（也就是 bins）。如：

$$[0,255]=[0,15]\cup[16,31]\cup\cdots\cup[240,255]$$

$$range = bin_1 \cup bin_2 \cup \cdots \cup bin_{n=15}$$



- 然后再统计每一个 $bin(i)$ 的像素数目。采用这一方法来统计上面的数字矩阵，可以得到下图（其中 x 轴表示 bin, y 轴表示各个 bin 中的像素个数）：



直方图表示





图像直方图例子



直方图表示

■ 图像直方图例子



■ 文本的词袋模型 (Bag of Words)

- 一种忽略顺序语法结构等信息的文本表示方法
- 将文本序列打散，只考虑每个单词的频率。



词袋模型

□ 文本的词袋模型 (Bag of Words)

- 忽略顺序的合理性？

研究表明

汉字的序顺并不定一能影响阅读

比如当你看完这句话后

仔细回味一下

才发现这段话里的字全是都乱的

□ 图像词袋模型




□ 图像词袋模型

- 1) 把图像分割成一个个patch，并对每个patch的中心点计算sift特征。sift算法可以提取图像中的局部不变特征，这一步是做dense sift.



□ 图像词袋模型

- 2) 利用kmeans算法, 将这些patch的中心点的sift特征聚成为k个类, 用这k个聚类中心来构造单词表。因为一幅图像中能提取出成千上万个sift向量, 而每个sift向量是128维的, 为了减小计算量, 需要对这些sift向量做聚类, 把相似的patch合并, 取聚类中心作代表, 构造单词表。
- 3) 利用单词表表示每幅图像, 则每幅图像被表示成了一个与词序列相对应的词频向量 (k维的)。





Skip-gram 模型

❑ 语言中的顺序关系

- 牛吃草、吃草牛、草吃牛
- 在词袋模型中，无法表达这种顺序关系

❑ 统计语言模型

对于语言序列

$$w_1, w_2, \dots, w_n$$

语言模型就是计算该序列的概率，即

$$P(w_1, w_2, \dots, w_n)$$

Skip-gram 模型

统计语言模型

o n-gram 语言模型

- ❖ 引入马尔可夫假设 (Markov assumption), 即假设当前词出现的概率只依赖于前 $n-1$ 个词, 可以得到

$$P(w_i | w_1, w_2, \dots, w_{i-1}) = P(w_i | w_{i-n+1}, \dots, w_{i-1})$$

$$n=1 \text{ unigram: } P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i)$$

$$n=2 \text{ bigram: } P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i | w_{i-1})$$

$$n=3 \text{ trigram: } P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i | w_{i-2}, w_{i-1})$$

Skip-gram 模型

统计语言模型


skip-gram 语言模型

- ❖ 在一个窗口内，中心词与与其上下文中出现的词的共现概率会更高。
- ❖ 假定：选定窗口后，窗口内的上下文词的概率只与中心词有关，与其它上下文词无关。

```
... lemon,  a [tablespoon of apricot jam,      a] pinch ...  
           c1      c2      t      c3          c4
```


- 跳字模型通过选择一段窗口内的上下文，以中心词来预测窗口内的其他词，来学习如何建模词与词间的上下文关系。

... lemon, a [tablespoon of apricot jam, a] pinch ...
c1 c2 t c3 c4



- ❑ <https://zhuanlan.zhihu.com/p/52061158>
- ❑ <http://mccormickml.com/2016/04/19/word2vec-tutorial-the-skip-gram-model/>
- ❑ *Speech and Language Processing*
- ❑ *Lecture: Visual Bag of Words - Stanford Vision Lab*
- ❑ <https://blog.csdn.net/chaipp0607/article/details/72236892>
- ❑ <https://blog.csdn.net/happyer88/article/details/45769413>