

根据学校课堂纪律的要求



请同学们坐在前五排





数字媒体技术基础

Meng Yang

www.smartllv.com

SUN YAT-SEN University



**机器智能与先进计算教
育部重点实验室**



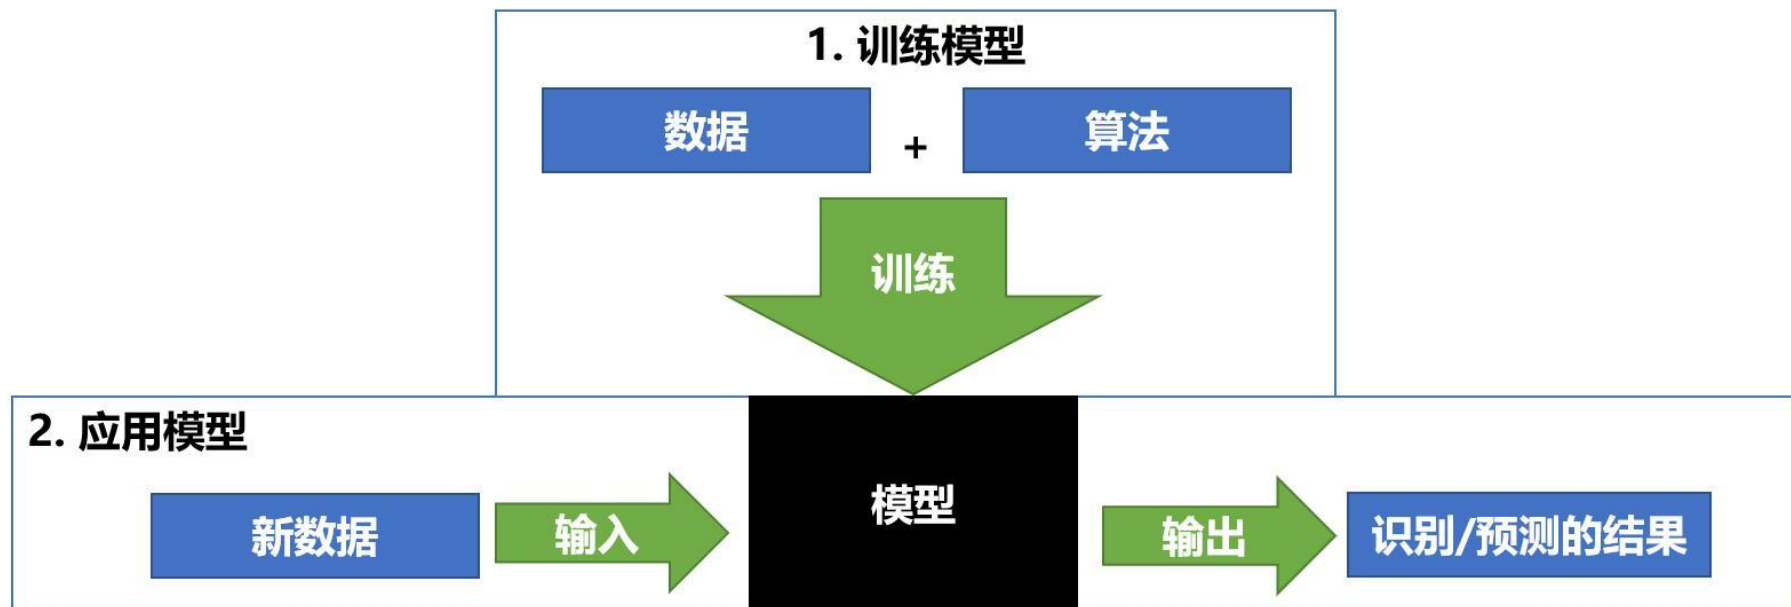
**智能视觉语言
学习研究组**

- ❑ 8. 数字媒体分类技术
 - ❑ 8.1 传统分类算法
 - 8.1.1 K-近邻分类器
 - 8.1.2 支持向量机
 - 8.1.3 稀疏协同表示分类器

第一部分

8.1 传统分类算法


分类器常规训练和测试过程



如何分类


■ 中心绿色点属于哪一类？

问题？




8.1.1 K-近邻分类器

- “物以类聚，人以群分”，K-近邻(K-Nearest Neighbor, KNN)学习就是利用这样一种思想发展起来的分类器。
- K-近邻学习是一种基于距离的分类器。




$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$



$$d = |x_1 - x_2| + |y_1 - y_2|$$

8.1.1 K-近邻分类器


- K-近邻学习是一种常用的**监督学习**方法，其工作机制非常简单：给定测试样本，基于某种距离度量找出训练集中与其最靠近的K个训练样本，然后基于这K个邻居的信息来进行预测。



如何给出类标签

- 已知点 C_4 的K的邻居和邻居的标签，
- 如何给出 C_4 的标签？

问题？



8.1.1 K-近邻分类器

- ❑ 通常在分类任务中可使用“投票法”，即选择K个样本中出现最多的类别标记作为预测结果；
- ❑ 回归任务中可使用“平均法”，将这K个样本的实值输出标记的平均值作为预测结果；
- ❑ 还可基于距离远近进行加权平均或者加权投票。

8.1.1 K-近邻分类器


- ❑ K-近邻学习没有显示的训练过程，是“懒惰学习” (lazy learning) 的著名代表。此类学习技术在训练阶段仅仅是把样本保存起来，训练时间开销为零，收到测试样本时再进行处理。
 - “急切学习” (eager learning)，是在训练阶段就对样本进行学习处理的方法。

应用模型



8.1.1 K-近邻分类器—K的取值

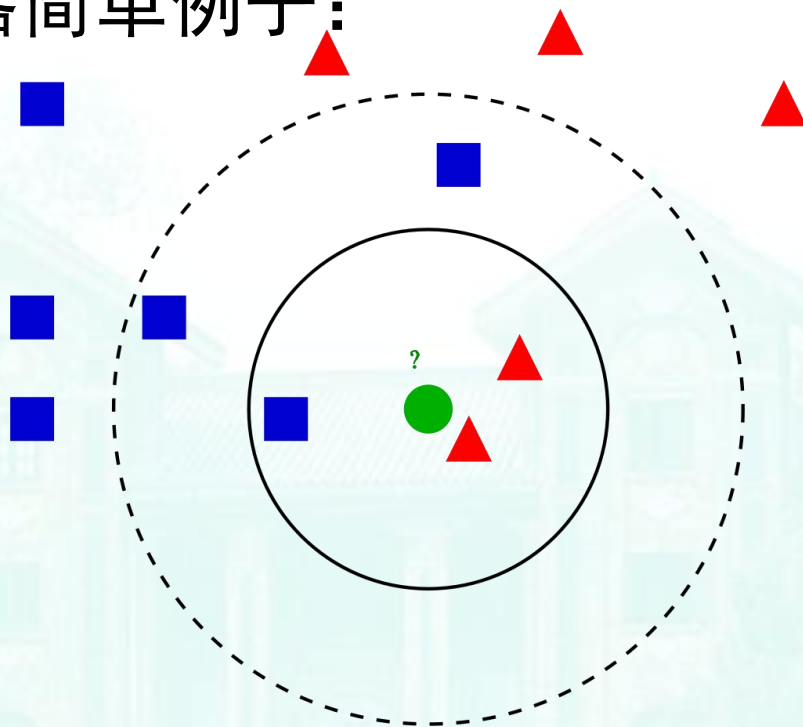
□ K-近邻分类器简单例子：



当 $k=3$ （等距线实线表示），有两个红色三角形和一个蓝色方形在实线内，被分类为红色三角形；

8.1.1 K-近邻分类器——K的取值

□ K-近邻分类器简单例子：



当 $k=5$ （虚线表示），有两个红色三角形和三个蓝色方形在虚线内，被分类为蓝色方形。

8.1.1 K-近邻分类器

- K-近邻分类器在设计过程中，有四个要点需要注意：
 - 用于对待分类对象所属类别进行评估的数据集合是什么，不一定需要使用整个数据集；
 - 用于计算对象之间相似度距离或者相似度矩阵如何计算，可以使用马氏距离，欧氏距离等等；
 - K值如何选取；
 - 用于确定待分类对象所属类别的方法是什么。

8.1.1 K-近邻分类器

□ K-近邻分类器算法总结：

Algorithm KNN

Input: D is the set of training objects; z is the test object, which is a vector of attribute values;
 L is the set of classes used to label the objects.

Output: $c_z \in L$ is the class of z

foreach object $y \in D$ **do**

 Compute $d(z, y)$, the distance between z and y ;

end

Select $N \subseteq D$, the set (neighborhood) of k closest training objects for z ;

$c_z = \operatorname{argmax}_{v \in L} \sum_{y \in N} I(v = \operatorname{class}(c_y))$;

where $I(\cdot)$ is an indicator function that returns the value 1 if its argument is true and 0 otherwise.

□ 算法复杂度： $\mathcal{O}(n)$

8.1.1 K-近邻分类器

□ K-近邻分类器总结：

- KNN算法简单且容易实现。当训练数据集很大时，需要大量的存储空间，而且需要计算待测样本和训练数据集中所有的样本距离，非常耗时。
- KNN对于对于类内间距小、类间间距大的数据集分类效果好，对于边界不规则的数据集效果好于线性分类器。
- KNN对于样本不均衡的数据效果不好，可以对 k 个邻居数据赋予权重。

8.1.1 K-近邻分类器



KNN很耗时，一般用于样本数少的数据集；当数据量大时，可以将数据以树的形式呈现。如KD树




图1 二维数据k-d树空间划分示意图





图3 上述实例生成的k-d树

8.1.2 支持向量机

- ❑ **线性可分**：在二维空间上，两类点被一条直线完全分开叫做线性可分。




8.1.2 线性可分数学表示

- 严格数学定义： D_0 和 D_1 是 n 维欧氏空间中的两个点集。如果存在 n 维向量 w 和实数 b ，使得所有属于 D_0 的点 x_i 都有 $w x_i + b > 0$ ，而对于所有属于 D_1 的点 x_j 都有 $w x_j + b < 0$ ，则称 D_0 和 D_1 线性可分。

8.1.2 支持向量机


- ❑ **间隔超平面**：从二维拓展到多维中，上述直线即拓展为一个超平面。
- ❑ 给定训练样本集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ，其中 $y_i \in \{-1, +1\}$ ，能把不同类别样本划分开的超平面不止一个：

问题？



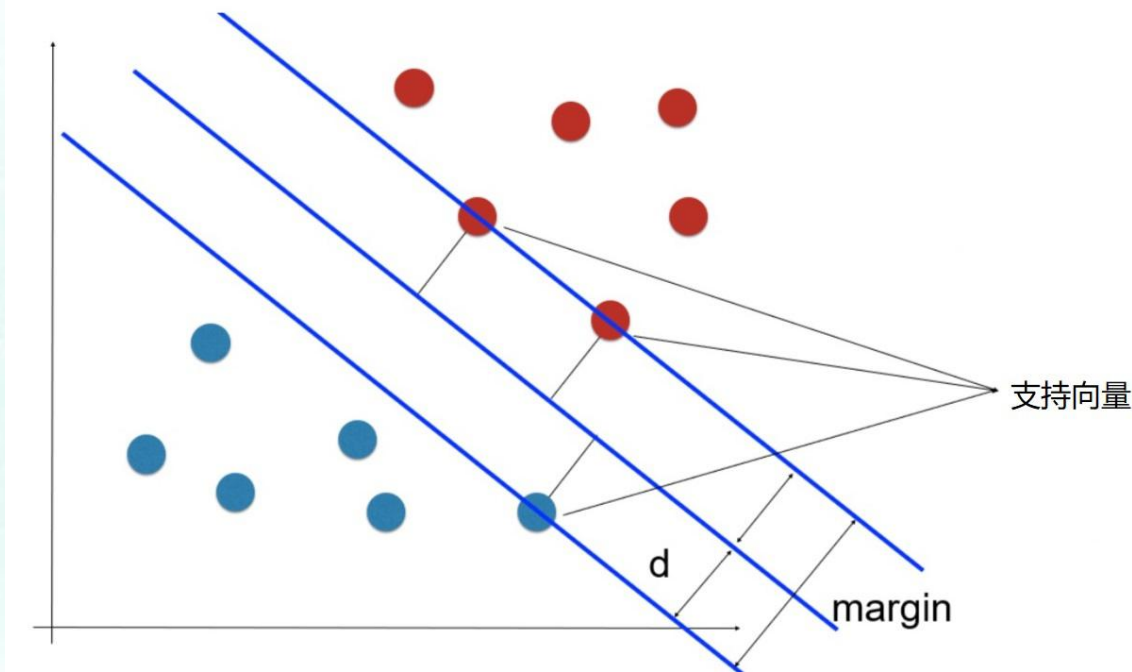
8.1.2 支持向量机

- 最大间隔超平面：两侧距离超平面最近的样本点到超平面的距离被最大化了。



8.1.2 支持向量机

- 支持向量 (support vector)：样本中距离超平面最近的样本点。



- 间隔 (margin)：两个异类支持向量到超平面的距离和。

8.1.2 支持向量机

□ 支持向量机**最优化问题**：即找到最大间隔超平面。

○ 任意超平面用以下线性方程描述：

$$w^T x + b = 0$$

其中 $w = (w_1; w_2; \dots; w_d)$ 为法向量决定超平面的方向； b 为位移项，决定超平面与原点之间的距离。

○ 样本空间中任意点 x 到超平面的距离可写为：

$$r = \frac{|w^T x + b|}{||w||}$$

○ 超平面需要将样本正确分类，满足以下公式：

$$\begin{cases} w^T x_i + b \geq +1, y_i = +1; \\ w^T x_i + b \leq -1, y_i = -1. \end{cases}$$

从公式看，支持向量就是使上述公式等号成立的几个样本点。

8.1.2 支持向量机

- 给定训练样本集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$, 其中 $y_i \in \{-1, +1\}$, 在这个前提下:

- 间隔 (margin): 两个异类支持向量到超平面的距离:

$$\gamma = \frac{2}{\|w\|}$$

- 找到最大间隔超平面的约束条件, 即让距离 γ 最大:

$$\max_{w, b} \frac{2}{\|w\|}$$

$$s. t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, m.$$

- 最大化间隔, 即最大化 $\|w\|^{-1}$, 即最小化 $\|w\|^2$:

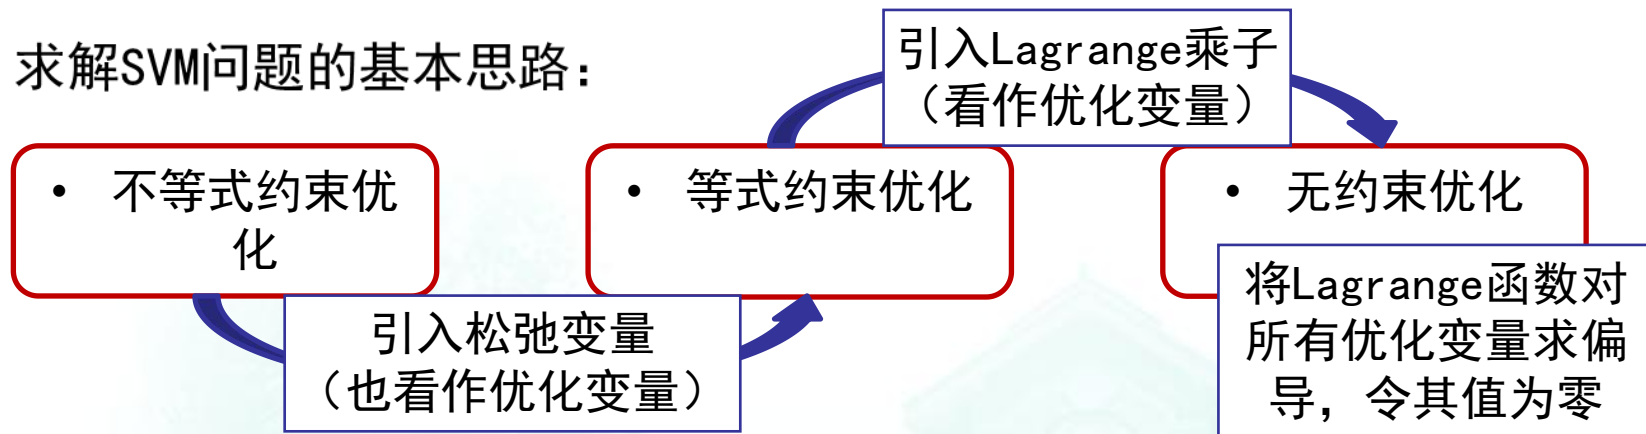
$$\min_{w, b} \frac{1}{2} \|w\|^2$$

$$s. t. y_i(w^T x_i + b) \geq 1, i = 1, 2, \dots, m.$$

这就是支持向量机 (Support Vector Machine, SVM) 的基本型。

8.1.2 支持向量机

- 求解SVM问题的基本思路：



- 引入拉格朗日乘子 α_i 将SVM问题得到其**对偶问题** (dual problem)：

拉格朗日函数： $L(w, b, \alpha) = \frac{1}{2} ||w||^2 + \sum_{i=1}^m \alpha_i (1 - y_i (w^T x_i + b))$

对 w 和 b 求偏导并令值为0得： $w = \sum_{i=1}^m \alpha_i y_i x_i$; $0 = \sum_{i=1}^m \alpha_i y_i$

将偏导带入拉格朗日函数，将 w 和 b 消去，得到对偶问题：

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j; s.t. \sum_{i=1}^m \alpha_i y_i = 0; \alpha_i \geq 0$$

8.1.2 支持向量机

- 如何求解：

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j; s. t. \sum_{i=1}^m \alpha_i y_i = 0; \alpha_i \geq 0$$

- 对于 α_i 和 α_j 来说，提出过许多高效算法，以顺序最小优化(Sequential Minimal Optimization, SMO)为例，不断执行如下两步直至收敛：

- 选取一对需要更新得变量 α_i 和 α_j ；
- 固定 α_i 和 α_j 以外的参数，求解上述公式获得更新后的 α_i 和 α_j 。

- 对于偏移量 b ，对于任意的支持向量 (x_s, y_s) ，都有 $y_s f(x_s) = 1$ ，即：


$$y_s (\sum_{i \in S} \alpha_i y_i x_i^T x_s + b) = 1, \text{ 其中 } S \text{ 是支持向量的下标集。}$$

- 理论上，选择任意一个支持向量求解可以得到 b ；
- 实际使用更鲁棒的方法：使用所有支持向量求解的平均值：

$$b = \frac{1}{|b|} \sum_{s \in S} \left(\frac{1}{y_s} - \sum_{i \in S} \alpha_i y_i x_i^T x_s \right)$$

8.1.2 支持向量机

- 若原始样本空间内不存在划分两类样本的超平面时，可以将原始空间映射到更高维的特征空间，使得其在更高维特征空间内线性可分：



- 使用非线性映射后的 $\phi(x)$ 代替 x ，之前最优化问题变为：

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(x_i)^T \phi(x_j); s. t. \sum_{i=1}^m \alpha_i y_i = 0; \alpha_i \geq 0$$

- 令： $\mathcal{K}(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle = \phi(x_i)^T \phi(x_j)$ ，即为“核函数” (Kernel function)。

8.1.2 支持向量机

□ 常用核函数：

名称	表达式	参数
线性核	$\mathcal{K}(x_i, x_j) = x_i^T x_j$	
多项式核	$\mathcal{K}(x_i, x_j) = (x_i^T x_j)^d$	$d \geq 1$ 为多项式次数
高斯核	$\mathcal{K}(x_i, x_j) = \exp(-\frac{\ x_i - x_j\ ^2}{2\sigma^2})$	$\sigma > 0$ 为高斯核的带宽
拉普拉斯核	$\mathcal{K}(x_i, x_j) = \exp(-\frac{\ x_i - x_j\ }{\sigma})$	$\sigma > 0$
Sigmoid 核	$\mathcal{K}(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta)$	\tanh 为双曲正切函数, $\beta > 0, \theta < 0$

8.1.2 支持向量机

□ 支持向量机总结：

- 支持向量机的求解通常时借助凸优化技术。如何提高效率，使SVM能适应大规模数据是研究重点之一。
- 支持向量机是针对二分类任务设计的，对多分类任务要进行专门的推广。
- 核函数直接决定了支持向量机的最终性能，但核函数的选择是一个未决问题。

8.1.3 稀疏协同表示分类器

❑ 稀疏表示 (Sparse Representation) :

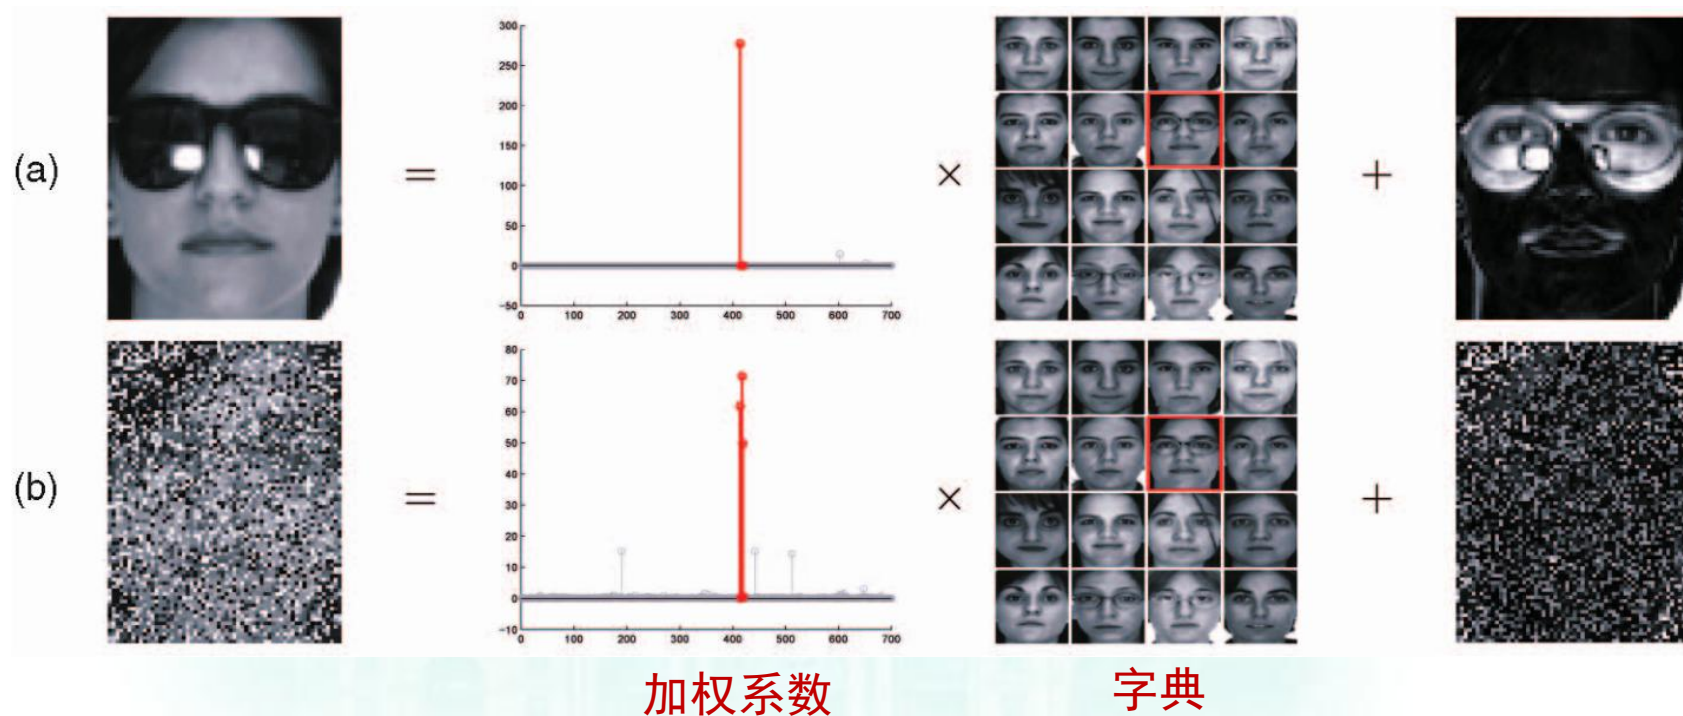
- 将给定的数据集 D 用矩阵的形式表示, 矩阵中存在许多零元素, 具有稀疏性。
- 如文档分类学习中, 将《现代汉语字典》中的汉字视为数据集 D , 用矩阵表示; 给定一个文档, 字典中大多数字不出现在这个文档中, 则矩阵具有大量零元素, 即为样本具有**稀疏性**。

❑ 字典学习 (Dictionary Learning) :

- 在一般的学习任务中, 没有给定的《现代汉语字典》, 需要为稠密表达的样本找到合适的字典, 转化为稀疏表示形式, 让模型复杂度得以降低, 这类方法为字典学习。

8.1.3 稀疏协同表示分类器


稀疏表示在人脸识别中的应用：



- 被遮挡 (a) 和损坏 (b) 图像，是所有训练图像的稀疏线性组合 (中间) 加上由于遮挡或损坏而引起的稀疏错误 (右)。

稀疏表示如何分类？

问题？



加权系数

字典

8.1.3 稀疏协同表示分类器

- ❑ 稀疏表示分类 (Sparse Representation Classification, SRC) 算法：从训练样本中抽取一定的样本构建词典，然后用词典表示测试样本，选取对应最小残差值的类作为预测结果。

8.1.3 稀疏协同表示分类器

- 若 X_i 表示第 i 类的训练样本，大小为 $d \times l_i$ ， d 为特征维数， l_i 为样本数量。将所有类别的训练样本合成一个矩阵 $D = [X_1 \dots X_i \dots X_K]$ ，大小为 $d \times l$ ，对于任意一个测试样本可以表示为如下线性方式：

$$y = D\alpha$$

由于 l 通常会远大于 d ，因此需要添加一个约束条件，得到 α 唯一解

$$y = D\alpha \quad \text{s.t.} \min \|\alpha\|_1$$

求解最优系数 α^* 后，利用残差确定相应类别：

$$y^* = \operatorname{argmin}_i e_i(y), e_i(y) = \|y - X_i \alpha_i\|_2$$

8.1.3 稀疏协同表示分类器

- 给定数据集 $\{x_1, x_2, \dots, x_m\}$, 字典学习最简单形式:

$$\min_{B, \alpha_i} \sum_{i=1}^m \|x_i - B\alpha_i\|_2^2 + \lambda \sum_{i=1}^m \|\alpha_i\|_1$$

其中 $B \in \mathbb{R}^{d \times k}$ 为字典矩阵, k 为字典词汇量, $\alpha_i \in \mathbb{R}^k$ 是样本 x_i 的稀疏表示。公式第一项让 α_i 能很好重构 x_i , 第二项让 α_i 更加稀疏。

- 求解第一步, 固定字典 B , 将公式按分量展开:

$$\min_{\alpha_i} \|x_i - B\alpha_i\|_2^2 + \lambda \|\alpha_i\|_1$$

- 求解第二步, 以 α_i 的初值来更新字典 B :

$$\min_B \|X - BA\|_F^2$$

8.1.3 稀疏协同表示分类器

- 协同表示分类 (Collaborative Representation Classification, CRC) 算法：当样本高度相关时，样本 y 在各个类的投影可能大致相同，SRC的结果就不稳定，于是CRC提出：

$$y = D\alpha \quad \text{s.t.} \min \|\alpha\|_2$$

或者表示为：

$$\min \|\alpha\|_2 \quad \text{s.t.} \|y - D\alpha\|_2 \leq \varepsilon$$